

למידה חישובית בייסיאנית, סמסטר א' 2022-2023

תרגיל 2 : רגרסיה לינארית בייסיאנית

רינה קרנאוך 319132353



הסטיקר שילווה אותנו

בתרגיל זה :

(זה חתול ישן ובריא ונושם)

1. חלק תאורטי

1.1. משערכים

בהינתן θ, α, γ הפרמטרים ו $\eta \sim \mathcal{N}(0, I\sigma^2)$ שאיננה ידועה. נתבונן על 3 דרכים של

פרמטריזציה של פולינומים מדרגה $k \in \mathbb{N}$.

$$y_\theta(x) = \sum_{n=1}^k \theta_n x^n + \eta \quad .i$$

$$y_\alpha(x) = \sum_{n=1}^k (10\alpha_n) x^n + \eta \quad .ii$$

$$y_\gamma(x) = \sum_{n=1}^k (\gamma_n)^3 x^n + \eta \quad .iii$$

א. נניח ואנו יודעים לחשב את $p_\theta(\theta|\mathcal{D})$, מה יהיו ההתפלגויות הבאות (ביחס להתפלגות $(p_\theta(\theta|\mathcal{D}))$:

לפני הסעיפים, נרצה לנתח את ה $posterior$ הנתון לנו :

$$y_\theta(x) = \sum_{n=1}^k \theta_n x^n + \eta$$

נוכל לסמן את הסכימה בתור מכפלת מטריצות :

$$\theta = \begin{pmatrix} \theta_1 \\ \dots \\ \theta_k \end{pmatrix}, H = [h_1(x), h_2(x), \dots, h_k(x)] \text{ s.t } \forall i \in [k] : h_i(x) = x^i$$

ונקבל :

$$y_\theta(x) = H\theta + \eta$$

a. $p_\alpha(\alpha|\mathcal{D})$ – נכתוב את $y_\alpha(x)$ בצורה שונה (בעזרת מטריצה H) :

$$y_\alpha(x) = 10H\alpha + \eta$$

אנו יודעים מהתרגול הראשון, שעבור פונקציה $\alpha \rightarrow \theta : f_1$ כך ש $f_1(\theta) = \alpha$ כך נקבל :

$$p_\alpha(\alpha|\mathcal{D}) = \left| \frac{\partial f_1^{-1}(\alpha)}{\partial \alpha} \right| p_\theta(f_1^{-1}(\alpha)|\mathcal{D})$$

ומשם נוכל לקבל את :

$$\mathbb{P}_\alpha(\alpha|\mathcal{D}) = \int_{-\infty}^{\alpha} p_\alpha(\tilde{\alpha}|\mathcal{D}) d\tilde{\alpha}$$

כעת נרצה למצוא את הפונקציה f_1 כנ"ל, וזאת בעזרת y :

$$y_{f_1(\theta)}(x) = y_\alpha(x) \rightarrow 10H \underbrace{f_1(\theta)}_\alpha + \eta = H\alpha + \eta$$

לכן :

$$f_1(\theta) = \underbrace{\frac{1}{10}\theta}_{\substack{\theta=10\alpha \\ \alpha=\frac{1}{10}\theta}} = \alpha \rightarrow f_1^{-1}(\alpha) = 10\alpha$$

ונקבל :

$$\begin{aligned} p_\alpha(\alpha|\mathcal{D}) &= \left| \frac{\partial f_1^{-1}(\alpha)}{\partial \alpha} \right| p_\theta(f_1^{-1}(\alpha)|\mathcal{D}) \\ &= \left| \begin{bmatrix} \frac{\partial(f_1^{-1}(\alpha))_1}{\partial \alpha_1} & \dots & \frac{\partial(f_1^{-1}(\alpha))_k}{\partial \alpha_1} \\ \vdots & \ddots & \vdots \\ \frac{\partial(f_1^{-1}(\alpha))_1}{\partial \alpha_k} & \dots & \frac{\partial(f_1^{-1}(\alpha))_k}{\partial \alpha_k} \end{bmatrix} \right| p_\theta(10\alpha|\mathcal{D}) \\ &= \left| 10 \begin{bmatrix} 1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & 1 \end{bmatrix} \right| = 10^k p_\theta(10\alpha|\mathcal{D}) \end{aligned}$$

b. $p_\gamma(\gamma|\mathcal{D}) -$ נכתוב את $y_\gamma(x)$ בצורה שונה (בעזרת מטריצה H) :
נגדיר :

$$\gamma = [\gamma_1, \gamma_2, \dots, \gamma_k]^T, \gamma^3 = [\gamma_1^3, \gamma_2^3, \dots, \gamma_k^3]^T$$

$$y_\gamma(\gamma) = H\gamma^3 + \eta$$

כעת נרצה למצוא פונקציה $\gamma : \theta \rightarrow \gamma$ כך שנקבל $f_2(\theta) = \gamma$ כאשר נצטרך ש :

$$y_{f_2(\theta)}(x) = y_\gamma(x)$$

כלומר :

$$H \underbrace{(f_2(\theta))}_{\gamma^3} + \eta = H\theta + \eta \rightarrow f_2(\theta) = \theta^{-3}$$

כלומר קיבלנו הגדרה עבור הפונקציה f_2^{-1} :

$$f_2^{-1}(x) = x^3$$

כאשר נגדיר שעבור ווקטור v :

$$v = \begin{bmatrix} v_1 \\ v_2 \\ \dots \\ v_k \end{bmatrix} \rightarrow v^p = \begin{bmatrix} v_1^p \\ v_2^p \\ \dots \\ v_k^p \end{bmatrix}$$

נקבל

$$p_\gamma(\gamma|\mathcal{D}) = \left| \frac{\partial f_2^{-1}(\gamma)}{\partial \gamma} \right| \cdot p_\theta(f_2^{-1}(\gamma)|\mathcal{D})$$

$$= \left\| \begin{bmatrix} \frac{\partial(f_2^{-1}(\gamma))_1}{\partial \gamma_1} & \dots & \frac{\partial(f_2^{-1}(\gamma))_k}{\partial \gamma_1} \\ \vdots & \ddots & \vdots \\ \frac{\partial(f_2^{-1}(\gamma))_1}{\partial \gamma_k} & \dots & \frac{\partial(f_2^{-1}(\gamma))_k}{\partial \gamma_k} \end{bmatrix} \right\| \cdot p_\theta(\gamma^3|\mathcal{D})$$

נקבל :

$$\begin{bmatrix} \frac{\partial(f_2^{-1}(\gamma))_1}{\partial \gamma_1} & \dots & \frac{\partial(f_2^{-1}(\gamma))_k}{\partial \gamma_1} \\ \vdots & \ddots & \vdots \\ \frac{\partial(f_2^{-1}(\gamma))_1}{\partial \gamma_k} & \dots & \frac{\partial(f_2^{-1}(\gamma))_k}{\partial \gamma_k} \end{bmatrix} = \begin{bmatrix} 3\gamma_1^2 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & 3\gamma_k^2 \end{bmatrix}$$

ולכן :

$$\det \left(\begin{bmatrix} 3\gamma_1^2 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & 3\gamma_k^2 \end{bmatrix} \right) = \prod_{i=1}^k 3\gamma_i^2 = 3^k \prod_{i=1}^k \gamma_i^2$$

ולכן :

$$p_\gamma(\gamma|\mathcal{D}) = \left(3^k \prod_{i=1}^k \gamma_i^2 \right) \cdot p_\theta(\gamma^3|\mathcal{D})$$

ב. נגדיר $k = 1$ כלומר נקבל ש $\theta, \alpha, \gamma \in \mathbb{R}$ מה גם :

$$y_\theta(x) = \theta x + \eta, y_\alpha(x) = 10\alpha x + \eta, y_\gamma(x) = \gamma^3 x + \eta$$

נגדיר $\hat{\theta}$ להיות $MMSE estimator$ של θ . נזכיר שמדובר ב $\mathbb{E}[\theta|\mathcal{D}]$ נשאלת השאלה האם הפתרונות

$$y_{\hat{\alpha}}(x), y_{\hat{\gamma}}(x) \text{ בהכרח יהיו בעלי אותו ערך עבור כל } x, \mathcal{D}. \text{ כעת :}$$

$$y_{\hat{\theta}}(x) = \hat{\theta}x + \eta, \quad y_{\hat{\alpha}}(x) = 10\hat{\alpha}x + \eta, \quad y_{\hat{\gamma}}(x) = \hat{\gamma}^3 x + \eta$$

כעת :

$$\hat{\alpha} = \mathbb{E}[\alpha|\mathcal{D}] = \int_{-\infty}^{\infty} p_\alpha(\tilde{\alpha}|\mathcal{D}) \cdot \tilde{\alpha} d\tilde{\alpha} = \int_{-\infty}^{\infty} p_\theta(10\tilde{\alpha}|\mathcal{D}) \cdot 10 \cdot \tilde{\alpha} d\tilde{\theta}$$

$$\hat{\gamma} = \mathbb{E}[\gamma|\mathcal{D}] = \int_{-\infty}^{\infty} p_\gamma(\tilde{\gamma}|\mathcal{D}) \cdot \tilde{\gamma} d\tilde{\gamma} = \int_{-\infty}^{\infty} p_\theta(\tilde{\gamma}^3|\mathcal{D}) \cdot 3\tilde{\gamma}^2 \cdot \tilde{\theta} d\tilde{\theta}$$

$$\text{אנו יודעים ש } \hat{\theta} \text{ ימזער את } \int_{-\infty}^{\infty} p_\theta(\tilde{\theta}|\mathcal{D}) \tilde{\theta} d\tilde{\theta} \text{ עבור כל ערך } \tilde{\theta}.$$

אנו יודעים שעבור כל θ, γ :

$$\gamma^3 = \theta, 10\alpha = \theta$$

כעת נרצה לבדוק אם מתקיים שהערכים הממוזערים גם כן מקיימים :

$$\hat{\gamma}^3 = \hat{\theta}, 10\hat{\alpha} = \hat{\theta}$$

והרי :

$$\hat{\alpha} = \int_{-\infty}^{\infty} p_{\theta} \left(\underbrace{10\tilde{\alpha}}_{\tilde{\theta}} \middle| \mathcal{D} \right) \cdot 10 \cdot \tilde{\alpha} d\tilde{\theta} = 10 \int_{-\infty}^{\infty} \underbrace{p_{\theta}(\tilde{\theta}|\mathcal{D})}_{\tilde{\theta}} \tilde{\theta} d\tilde{\theta} = 10\hat{\theta}$$

כלומר קיים שוויון בין הממוזערים כנ"ל.

$$\hat{\gamma} = \int_{-\infty}^{\infty} p_{\theta}(\tilde{\gamma}^3|\mathcal{D}) \cdot 3\tilde{\gamma}^2 \cdot \tilde{\theta} d\tilde{\theta} = 3 \int_{-\infty}^{\infty} p_{\theta} \left(\underbrace{\tilde{\gamma}^3}_{\tilde{\theta}} \middle| \mathcal{D} \right) \cdot \underbrace{\tilde{\gamma}^2}_{\tilde{\theta}} \cdot \tilde{\theta} d\tilde{\theta} = 3 \int_{-\infty}^{\infty} p_{\theta}(\theta|\mathcal{D}) \cdot \tilde{\theta}^3 d\tilde{\theta}$$

אבל ערך זה איננו שווה ל $\int_{-\infty}^{\infty} p_{\theta}(\theta|\mathcal{D}) \cdot \tilde{\theta} d\tilde{\theta} = \hat{\theta}$, על כן :

$$\hat{\gamma} \neq \hat{\theta}$$

1.2. רגרסיה לינארית בייסיאנית

בהינתן 2 מדגמים $\mathcal{D}_1, \mathcal{D}_2$ ובעיית רגרסיה. בשני המדגמים זוגות (x_i, y_i) ואנו מניחים שעבור שני המדגמים :

$$y_i = \sum_{n=1}^d \theta_n h_n(x_i) + \eta$$

עבור קבוצת פונקציות בסיס $\{h_i(\cdot)\}_{i \in [d]}$, כאשר $\eta \sim \mathcal{N}(0, I\sigma^2)$. נניח $prior$ גאוסיאני עבור θ כלומר :

$$\theta \sim \mathcal{N}(\mu, \Sigma)$$

i. נרצה להוכיח כי מתקיים :

$$p(\theta, D_1, D_2) = p(\theta)p(D_1|\theta)p(D_2|\theta)$$

והרי מהגדרת התפלגות משותפת נוכל לרשום :

$$p(\theta, D_1, D_2) = p(\theta) \cdot \underbrace{p(D_1, D_2|\theta)}_{\forall d_1, d_2 \in D_1 \cup D_2 : d_1 \perp d_2} = p(\theta) \cdot p(D_1|\theta) \cdot p(D_2|\theta)$$

וקיבלנו את הדרוש.

ii. נרצה למצוא את $p(\theta|D_1, D_2)$. והרי :

$$p(\theta|D_1, D_2) \cdot p(D_1, D_2) = p(\theta, D_1, D_2) = p(\theta) \cdot p(D_1|\theta) \cdot p(D_2|\theta)$$

לכן :

$$\begin{aligned} p(\theta|D_1, D_2) &= \frac{p(\theta) \cdot p(D_1|\theta) \cdot p(D_2|\theta)}{p(D_1, D_2)} \stackrel{\forall d_1, d_2 \in D_1 \cup D_2, d_1 \perp d_2}{=} \frac{p(\theta) \cdot p(D_1|\theta) \cdot p(D_2|\theta)}{p(D_1) \cdot p(D_2)} \\ &= \frac{p(\theta) \cdot p(D_1|\theta)}{p(D_1)} \cdot \frac{p(D_2|\theta)}{p(D_2)} \end{aligned}$$

כלומר נקבל ש :

$$p(\theta|D_1, D_2) \propto p(\theta) \cdot p(D_1|\theta) \cdot p(D_2|\theta)$$

והרי אנו יודעים שעבור $\theta \sim \mathcal{N}(\mu, \Sigma)$ מה גם :

$$\forall d_i = (x_i, y_i) \in D_1 \cup D_2 : y_i = \sum_{n=1}^d \theta_n h_n(x_i) + \eta \text{ s.t. } \eta \sim \mathcal{N}(0, I\sigma^2)$$

בפרט עבור $d_i \in D_1$ נגדיר :

$$H_1 = \begin{pmatrix} h^T(x_{1,1}) \\ \dots \\ h^T(x_{1,N_1}) \end{pmatrix}, H_2 = \begin{pmatrix} h^T(x_{2,1}) \\ \dots \\ h^T(x_{2,N_2}) \end{pmatrix}$$

כאשר $\forall j \in \{1,2\} : N_j = |D_j|, \forall i \in [N_j] : x_{j,i} \in D_j$

כעת אנו יודעים ש

$$p(\theta|D_1, D_2) = \underbrace{\frac{p(\theta) \cdot p(D_1|\theta)}{p(D_1)}}_{\sim \mathcal{N}(\mu_{\theta|D_1}, \Sigma_{\theta|D_1})} \cdot \frac{p(D_2|\theta)}{p(D_2)}$$

ולכן נקבל גם שכלל ההתפלגות גאוסיאנית שהרי מדובר במכפלה בגאוסיאן. נוכל לומר ש :

$$p(\theta|D_1, D_2) \cdot p(\theta) = \frac{p(\theta) \cdot p(D_1|\theta)}{p(D_1)} \cdot \frac{p(\theta) \cdot p(D_2|\theta)}{p(D_2)}$$

$$p(\theta|D_1, D_2) \propto \frac{p(\theta) \cdot p(D_1|\theta)}{p(D_1)} \cdot \frac{p(\theta) \cdot p(D_2|\theta)}{p(D_2)}$$

וכעת נשתמש בידע שלנו על ההתפלגויות $\theta|D_1, \theta|D_2, \theta$ ותכונות האקספוננט :

נקבל שם :

$$\forall i \in [2] : p(\theta|D_i) \sim \mathcal{N}(H_i \theta, I\sigma^2)$$

נגדיר :

$$\forall i \in [2] : x_i = \begin{bmatrix} x_{i,1} \\ \dots \\ x_{i,N_i} \end{bmatrix}, y_i = \begin{bmatrix} y_{i,1} \\ \dots \\ y_{i,N_i} \end{bmatrix}$$

$$p(\theta|D_1, D_2) \propto \exp \left[-\frac{1}{2} (y_1 - H_1 \theta)^T \frac{1}{\sigma^2} I (y_1 - H_1 \theta) - \frac{1}{2} (\theta - \mu)^T \Sigma^{-1} (\theta - \mu) \right. \\ \left. - \frac{1}{2} (y_2 - H_2 \theta)^T \frac{1}{\sigma^2} I (y_2 - H_2 \theta) \right]$$

כעת נרצה לגזור את תוכן האקספוננט בכדי לקבל את $\mu_{\theta|D_1, D_2}, \Sigma_{\theta|D_1, D_2}$ על פי טריק הנגזרת.

נגזור את $\{value \text{ inside exponent}\}$ קרי :

$$\Delta = -\frac{1}{2} \underbrace{(y_1 - H_1 \theta)^T \frac{1}{\sigma^2} I (y_1 - H_1 \theta)}_{\Delta_1 = m^T \frac{1}{\sigma^2} I m} - \frac{1}{2} \underbrace{(\theta - \mu)^T \Sigma^{-1} (\theta - \mu)}_{\Delta_2}$$

$$- \frac{1}{2} \underbrace{(y_2 - H_2 \theta)^T \frac{1}{\sigma^2} I (y_2 - H_2 \theta)}_{\Delta_3}$$

נקבל:

$$\frac{\partial \Delta}{\partial \theta} = \frac{\partial \Delta_1}{\partial \theta} + \frac{\partial \Delta_2}{\partial \theta} + \frac{\partial \Delta_3}{\partial \theta}$$

כעת נחשב:

$$\frac{\partial \Delta_1}{\partial \theta} = \frac{1}{\sigma^2} I \cdot H_1^T (H_1 \theta - y_1)$$

$$\frac{\partial \Delta_2}{\partial \theta} = \Sigma^{-1} (\theta - \mu)$$

$$\frac{\partial \Delta_3}{\partial \theta} = \frac{1}{\sigma^2} I \cdot H_2^T (H_2 \theta - y_2)$$

כעת:

$$\frac{\partial \Delta}{\partial \theta} = \left(\frac{1}{\sigma^2} I \cdot H_1^T (H_1 \theta - y_1) + \Sigma^{-1} (\theta - \mu) + \frac{1}{\sigma^2} I \cdot H_2^T (H_2 \theta - y_2) \right)$$

נפתח ונקבל:

$$\frac{\partial \Delta}{\partial \theta} = \frac{1}{\sigma^2} H_1^T H_1 \theta - \frac{1}{\sigma^2} H_1^T y_1 + \frac{1}{\sigma^2} H_2^T H_2 \theta - \frac{1}{\sigma^2} H_2^T y_2 - \Sigma^{-1} \mu + \Sigma^{-1} \theta =$$

$$\frac{\partial \Delta}{\partial \theta} = \left(\frac{1}{\sigma^2} H_1^T H_1 + \frac{1}{\sigma^2} H_2^T H_2 + \Sigma^{-1} \right) \theta - \left[\frac{1}{\sigma^2} H_1^T y_1 + \frac{1}{\sigma^2} H_2^T y_2 - \Sigma^{-1} \mu \right]$$

$$= \left(\overbrace{\frac{1}{\sigma^2} H_1^T H_1 + \frac{1}{\sigma^2} H_2^T H_2 + \Sigma^{-1}}^{\Sigma_{\theta|D_1, D_2}} \right) \left[\theta - \underbrace{\left(\frac{1}{\sigma^2} H_1^T y_1 + \frac{1}{\sigma^2} H_2^T y_2 - \Sigma^{-1} \mu \right)}_{\mu_{\theta|D_1, D_2}} \cdot \left(\frac{1}{\sigma^2} H_1^T H_1 + \frac{1}{\sigma^2} H_2^T H_2 + \Sigma^{-1} \right)^{-1} \right]$$

ולכן:

$$p(\theta|D_1, D_2) \sim \mathcal{N} \left(\left(\frac{1}{\sigma^2} H_1^T y_1 + \frac{1}{\sigma^2} H_2^T y_2 - \Sigma^{-1} \mu \right) \cdot \left(\frac{1}{\sigma^2} H_1^T H_1 + \frac{1}{\sigma^2} H_2^T H_2 + \Sigma^{-1} \right)^{-1}, \left(\frac{1}{\sigma^2} H_1^T H_1 + \frac{1}{\sigma^2} H_2^T H_2 + \Sigma^{-1} \right)^{-1} \right)$$

.iii נניח וביצענו רגרסיה לינארית בייזיאנית כך שיש לנו את :

$$\mu_{\theta, D_1}, \mu_{\theta, D_2}, \Sigma_{\theta|D_1}, \Sigma_{\theta|D_2}$$

נרצה להוכיח שניתן לחשב את $\hat{\theta}^{MMSE} = \mathbb{E}[\theta|D]$ עבור θ נתון בהינתן $\mu_{\theta|D_i}, \Sigma_{\theta|D_i} : \forall i \in [2]$.

אנו יודעים ש

$$\mu_{\theta|D_1, D_2} = \mathbb{E}[\theta|D] = \hat{\theta}^{MMSE}$$

בנוסף אנו יודעים כי :

$$\frac{\partial \Delta_1}{\partial \theta} = \frac{1}{\sigma^2} I \cdot H_1^T (H_1 \theta - y_1) = \frac{1}{\underbrace{\sigma^2}_{\Sigma_{\theta|D_1}^{-1} - \Sigma_{\theta}^{-1}}} H_1^T H_1 \left(\theta - \underbrace{H_1^{-1} y_1}_{\mu_{\theta|D_1}} \right)$$

$$\frac{\partial \Delta_2}{\partial \theta} = \underbrace{\Sigma_{\theta}^{-1}}_{\Sigma_{\theta}^{-1}} \left(\theta - \underbrace{\mu}_{\mu_{\theta}} \right)$$

$$\frac{\partial \Delta_3}{\partial \theta} = \frac{1}{\sigma^2} I \cdot H_2^T (H_2 \theta - y_2) = \frac{1}{\underbrace{\sigma^2}_{\Sigma_{\theta|D_1}^{-1} - \Sigma_{\theta}^{-1}}} H_2^T H_2 \left(\theta - \underbrace{H_2^{-1} y_2}_{\mu_{\theta|D_2}} \right)$$

כעת נבחין כי :

$$\left(\frac{1}{\sigma^2} H_1^T H_1 + \Sigma^{-1} + \frac{1}{\sigma^2} H_2^T H_2 \right) = \Sigma_{\theta|D_1}^{-1} + \Sigma_{\theta|D_2}^{-1} - \Sigma_{\theta}^{-1} = \Sigma_{\theta|D_1, D_2}^{-1}$$

$$\underbrace{\frac{1}{\sigma^2} H_1^T y_1}_{\frac{1}{\sigma^2} H_1^T H_1 \cdot H_1^{-1} y_1} + \Sigma^{-1} \mu + \underbrace{\frac{1}{\sigma^2} H_2^T y_2}_{\frac{1}{\sigma^2} H_2^T H_2 \cdot H_2^{-1} y_2} = \Sigma_{\theta|D_1}^{-1} \cdot \mu_{\theta|D_1} - \Sigma_{\theta}^{-1} \mu_{\theta} + \Sigma_{\theta|D_2}^{-1} \cdot \mu_{\theta|D_2}$$

והרי

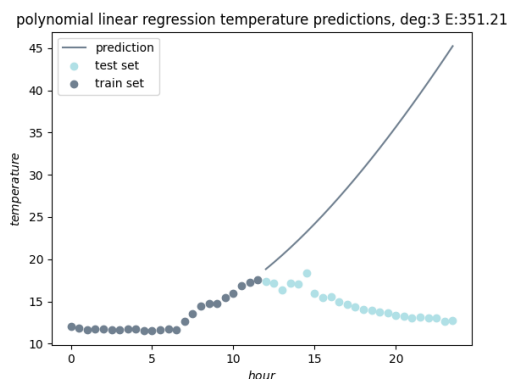

$$\hat{\theta}^{MMSE} = \mathbb{E}[\theta|D] = \left(\frac{\frac{1}{\sigma^2} H_1^T y_1 + \frac{1}{\sigma^2} H_2^T y_2 + \Sigma^{-1} \mu}{\Sigma_{\theta|D_1}^{-1} \cdot \mu_{\theta|D_1} + \Sigma_{\theta}^{-1} \mu_{\theta} + \Sigma_{\theta|D_2}^{-1} \cdot \mu_{\theta|D_2}} \right) \cdot \frac{\left(\frac{1}{\sigma^2} H_1^T H_1 + \frac{1}{\sigma^2} H_2^T H_2 + \Sigma^{-1} \right)^{-1}}{\left(\Sigma_{\theta|D_1}^{-1} - \Sigma_{\theta}^{-1} + \Sigma_{\theta|D_2}^{-1} \right)^{-1}}$$

ולכן :

$$\hat{\theta}^{MMSE} = \left(\Sigma_{\theta|D_1}^{-1} \cdot \mu_{\theta|D_1} - \Sigma_{\theta}^{-1} \mu_{\theta} + \Sigma_{\theta|D_2}^{-1} \cdot \mu_{\theta|D_2} \right) \cdot \left(\Sigma_{\theta|D_1}^{-1} + \Sigma_{\theta|D_2}^{-1} - \Sigma_{\theta}^{-1} \right)^{-1}$$

2. חלק פרקטי



- 2.1. היינו צריכים למדל רגרסיה לינארית קלאסית. זה נעשה במחלקה הניתנה לנו.
- 2.2. היינו צריכים למדל רגרסיה לינארית בייזיאנית, זה נעשה במחלקה הניתנה לנו.
- 2.3. באימון המודל הקלאסי קיבלנו את התוצאות הבאות (ביחס ל deg שניתן לנו):



בכותרת הגרף מצורפים ערכי ה MSE עבור כל מודל כתלות ב deg .


2.4 אימנו $prior$.

2.5 נייצג את $mean$ functions שמוגדרות על ידי $prior$ ביחד עם רווח הסמך ובנוסף 5 פונקציות בעזרת $prior$ שלמדנו, ביחס ל deg :

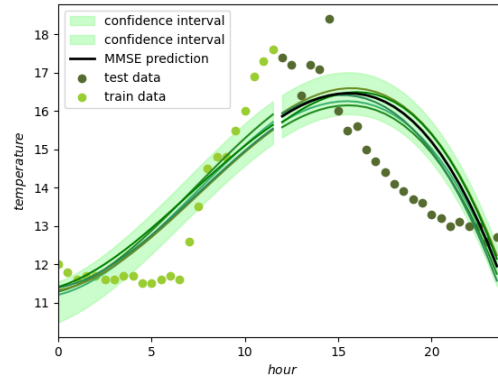


2.6 נתאים את המודל ל $test$ ונקבל את ה $posterior$. נייצג את ה $true test$ ביחד עם הפרדיקציה עם הרווח הסמך מסביב אליה, ובנוסף 5 פונקציות נוספות שנלמדו בעזרת ה $posterior$, ביחס ל deg :

polynomials :bayesian linear regression, prior distribution, deg=7 E:0.35




polynomials :bayesian linear regression, prior distribution, deg=3 E:1.90




ה MSE של ה $MMSE$ מצורפת בכותרת ה `plot`:

2.7 נבצע את סעיפים 4-6 על פונקציות בסיס גאוסיאניות :

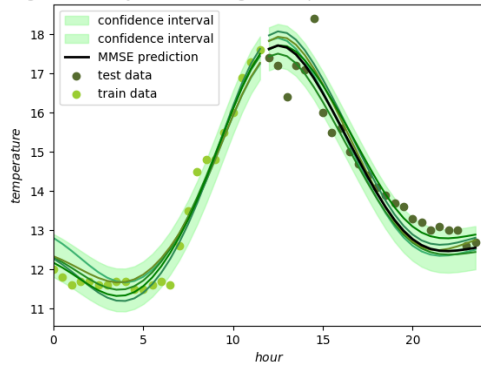
gaussians :bayesian linear regression, prior distribution, S1 E:0.38




bayesian linear regression, prior distribution, S1



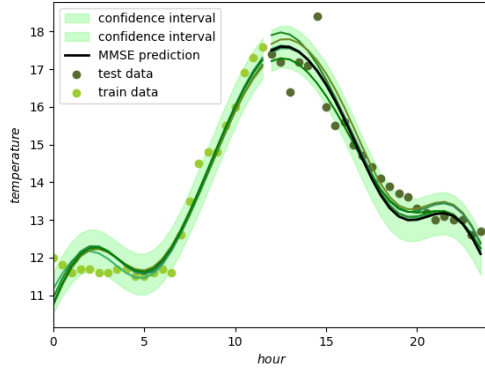
gaussians :bayesian linear regression, prior distribution, S2 E:0.31




bayesian linear regression, prior distribution, S2



gaussians :bayesian linear regression, prior distribution, S3 E:0.27




bayesian linear regression, prior distribution, S3




2.8 נבצע את סעיפים 4-6 על פונקציות בסיס Cubic Splines :


Spline :bayesian linear regression, prior distribution, K1 E:1.13



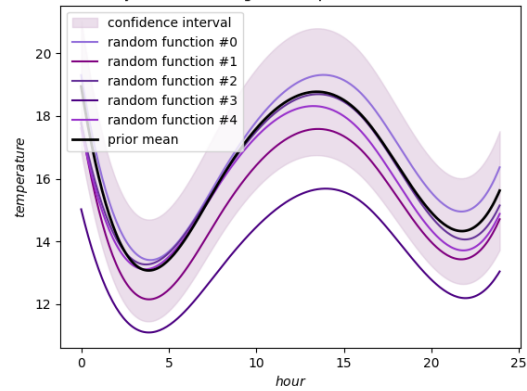
bayesian linear regression, prior distribution, K1

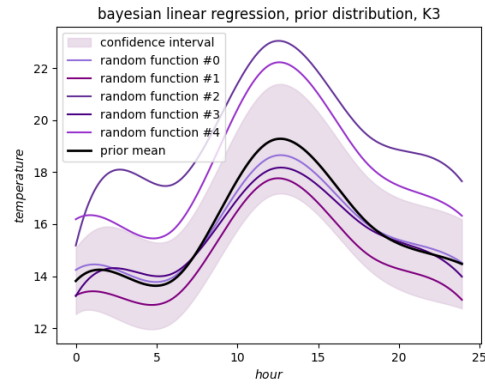
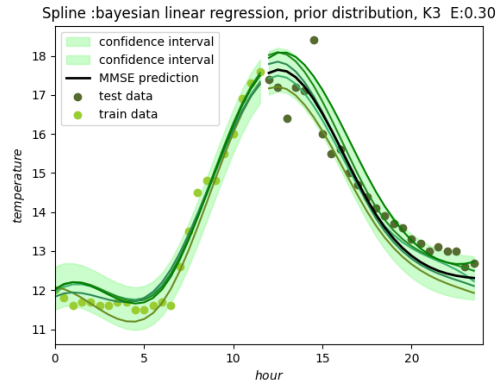


Spline :bayesian linear regression, prior distribution, K2 E:0.94



bayesian linear regression, prior distribution, K2





2.9 נתבונן על ה MSE של הפתרונות שלנו :

Average squared error with LR and d=3 is 351.21
 Average squared error with LR and d=7 is 848707.53
 Average squared error with BLR and deg=3 is 1.90
 Average squared error with BLR and deg=7 is 0.35
 Average squared error with BLR and S1 is 0.38
 Average squared error with BLR and S2 is 0.31
 Average squared error with BLR and S3 is 0.27
 Average squared error with BLR and K1 is 1.13
 Average squared error with BLR and K2 is 0.94
 Average squared error with BLR and K3 is 0.30